

Ejercicio 2 - Medición de riesgo de crédito con simulación Monte Carlo

En este ejercicio se estima la distribución de pérdidas para dos carteras: **gubernamental** y **auto**.

```
In [15]: import pandas as pd
import numpy as np
from scipy.stats import norm
import matplotlib.pyplot as plt
from matplotlib.ticker import FuncFormatter, PercentFormatter
from IPython.display import display, Markdown

plt.style.use("seaborn-v0_8-whitegrid")
pd.options.display.float_format = "{:,.4f}".format
```

Parámetros del análisis

- `rho` representa la correlación de activos asumida entre acreditados.
- `n_sim` controla el número de escenarios Monte Carlo.
- La pérdida por crédito se define como `EAD * LGD` cuando ocurre incumplimiento.

```
In [16]: archivo_excel = r"Tarea 2.xlsx"
hoja = "Ejercicio 2 (Datos)"

rho = 0.20
n_sim = 20_000
seed = 42
percentiles = [95, 99, 99.9]

raw = pd.read_excel(archivo_excel, sheet_name=hoja, header=None)
print(f"Base cargada: {raw.shape[0]:,} filas x {raw.shape[1]:,} columnas")
```

Base cargada: 9,802 filas x 16 columnas

¿Cómo se hace la simulación?

La cartera se modela crédito por crédito. Para cada acreditado i , se usan tres variables principales:

- EAD _{i} : exposición al momento del incumplimiento.
- LGD _{i} : severidad de la pérdida, es decir, proporción no recuperada.
- PD _{i} : probabilidad de incumplimiento.

Si el crédito i incumple, su pérdida es:

$$L_i = \text{EAD}_i \times \text{LGD}_i$$

La pérdida total de la cartera en un escenario simulado es:

$$L = N \sum_{i=1} I_i \cdot \text{EAD}_i \cdot \text{LGD}_i$$

Donde I_i es una variable indicadora:

$$I_i = \begin{cases} 1, & \text{si el crédito incumple} \\ 0, & \text{si el crédito no incumple} \end{cases}$$

Modelo de un factor gaussiano

Para incorporar dependencia entre incumplimientos se usa un factor sistemático común M , que representa el estado general de la economía o del mercado. El valor latente del acreditado se escribe como:

$$X_i = \sqrt{\rho}M + \sqrt{1 - \rho}\epsilon_i$$

Donde:

- $M \sim N(0, 1)$ es el factor común.
- $\epsilon_i \sim N(0, 1)$ es el riesgo idiosincrático del crédito.
- ρ es la correlación de activos.

El crédito incumple si su variable latente cae por debajo de un umbral asociado a su probabilidad de incumplimiento:

$$X_i < \Phi^{-1}(PD_i)$$

Condicionado al factor común M , la probabilidad de incumplimiento se calcula como:

$$PD_i(M) = \Phi\left(\Phi^{-1}(PD_i) - \sqrt{\rho}M\sqrt{1 - \rho}\right)$$

Esta es la fórmula que aparece en el código como `conditional_pd`. Después, para cada simulación, se genera un número uniforme $U_i \sim U(0, 1)$. El crédito incumple cuando:

$$U_i < PD_i(M)$$

Medidas de riesgo

La pérdida esperada es el promedio de las pérdidas simuladas:

$$EL = E[L]$$

También puede aproximarse de forma analítica como:

$$EL \approx N \sum_{i=1} PD_i \cdot EAD_i \cdot LGD_i$$

El VaR al nivel α es el percentil α de la distribución de pérdidas:

$$VaR_{\alpha} = \inf$$

Por ejemplo, $VaR_{\{99\%}}$ indica una pérdida que solo se supera en aproximadamente 1 de cada 100 escenarios simulados.

El Expected Shortfall mide la pérdida promedio en los escenarios que exceden el VaR:

$$ES_{\alpha} = \mathbb{E}[L \mid L \geq VaR_{\alpha}]$$

Finalmente, el capital económico se calcula como la pérdida extrema menos la pérdida esperada:

$$Capital_{Económico_{\alpha}} = VaR_{\alpha} - EL$$

La pérdida esperada mide el costo promedio del riesgo, mientras que VaR, ES y capital económico describen qué tan severa puede ser la cola de pérdidas bajo escenarios adversos.

Funciones auxiliares

```
In [17]: def money(x, decimals=0):
    return f"${x:,.{decimals}f}"

def pct(x, decimals=2):
    return f"{100 * x:.{decimals}f}%"

def prepare_gubernamental(raw):
    gub_raw = raw.iloc[2:4638, 0:7].copy()
    gub_raw.columns = [
        "CVE_PERI", "CVE_INSTI", "DAT_ID_CRED", "DAT_RESPONSA",
        "DAT_SP_TI", "DAT_EPRC", "DAT_PI_TOTAL"
    ]

    gub = pd.DataFrame({
        "EAD": pd.to_numeric(gub_raw["DAT_RESPONSA"], errors="coerce"),
        "LGD": pd.to_numeric(gub_raw["DAT_SP_TI"], errors="coerce") / 100,
        "PD": pd.to_numeric(gub_raw["DAT_PI_TOTAL"], errors="coerce") / 100,
    })

    gub = gub.dropna()
    gub = gub[(gub["EAD"] > 0) & (gub["LGD"] > 0) & (gub["PD"] > 0)].copy()
    gub["EAD_LGD"] = gub["EAD"] * gub["LGD"]
    gub["EL_individual"] = gub["EAD_LGD"] * gub["PD"]
    return gub
```

```

def prepare_auto(raw):
    auto_raw = raw.iloc[2:4638, 9:16].copy()
    auto_raw.columns = ["Fecha", "Inst", "FolioCred", "SdoCred", "SeveriNC", "Rvas", "Probab"]

    auto = pd.DataFrame({
        "EAD": pd.to_numeric(auto_raw["SdoCred"], errors="coerce"),
        "LGD": pd.to_numeric(auto_raw["SeveriNC"], errors="coerce"),
        "PD": pd.to_numeric(auto_raw["Probab"], errors="coerce") / 100,
        "Rvas": pd.to_numeric(auto_raw["Rvas"], errors="coerce"),
    }).astype({
        "EAD": "float64",
        "LGD": "float64",
        "PD": "float64",
        "Rvas": "float64",
    })

    denominador = auto["EAD"] * auto["PD"]
    lgd_calculada = np.divide(
        auto["Rvas"],
        denominador,
        out=np.full(len(auto), np.nan, dtype="float64"),
        where=denominador.to_numpy() != 0,
    )

    mask = auto["LGD"].isna() | (auto["LGD"] == 0)
    auto["LGD"] = np.where(mask, lgd_calculada, auto["LGD"].to_numpy(dtype="float64"))

    auto = auto.replace([np.inf, -np.inf], np.nan).dropna()
    auto = auto[(auto["EAD"] > 0) & (auto["LGD"] > 0) & (auto["LGD"] <= 1) & (auto["PD"] > 0)].copy()
    auto["EAD_LGD"] = auto["EAD"] * auto["LGD"]
    auto["EL_individual"] = auto["EAD_LGD"] * auto["PD"]
    return auto.drop(columns=["Rvas"])

def portfolio_profile(df, name):
    weights_ead = df["EAD"] / df["EAD"].sum()
    weights_el = df["EL_individual"] / df["EL_individual"].sum()
    top_10_ead_share = df.nlargest(10, "EAD")["EAD"].sum() / df["EAD"].sum()
    hhi = np.square(weights_ead).sum()

    profile = pd.DataFrame({
        "Metrica": [
            "Numero de creditos", "EAD total", "EAD promedio", "EAD mediana",
            "PD promedio simple", "PD ponderada por EAD", "LGD promedio simple",
            "LGD ponderada por EAD", "Perdida esperada analitica", "EL / EAD",
            "Participacion top 10 por EAD", "HHI de concentracion"
        ],
        name: [
            len(df), df["EAD"].sum(), df["EAD"].mean(), df["EAD"].median(),
            df["PD"].mean(), np.average(df["PD"], weights=df["EAD"]), df["LGD"].mean(),
            np.average(df["LGD"], weights=df["EAD"]), df["EL_individual"].sum(),
            df["EL_individual"].sum() / df["EAD"].sum(), top_10_ead_share, hhi
        ]
    })
    return profile

def simulate_one_factor_losses(df, rho=0.20, n_sim=20_000, seed=42):
    rng = np.random.default_rng(seed)
    market_factor = rng.normal(0, 1, n_sim)
    losses = np.zeros(n_sim)
    sqrt_rho = np.sqrt(rho)
    sqrt_1_rho = np.sqrt(1 - rho)

    for pd_val, group in df.groupby("PD", sort=False):
        threshold = norm.ppf(pd_val)
        conditional_pd = norm.cdf((threshold - sqrt_rho * market_factor) / sqrt_1_rho)
        conditional_pd = np.clip(conditional_pd, 0, 1)
        exposure_at_loss = group["EAD_LGD"].to_numpy()
        uniforms = rng.uniform(size=(n_sim, len(exposure_at_loss)))
        losses += (uniforms < conditional_pd[:, None]) @ exposure_at_loss

    return losses

def loss_metrics(losses, df, name):
    metrics = {
        "EL simulada": losses.mean(),
        "EL analitica": df["EL_individual"].sum(),
        "Desviacion estandar": losses.std(ddof=1),
    }

    for q in percentiles:

```

```

        var = np.percentile(losses, q)
        es = losses[losses >= var].mean()
        metrics[f"VaR {q}%"] = var
        metrics[f"ES {q}%"] = es
        metrics[f"Capital economico {q}%"] = var - losses.mean()

    return pd.DataFrame({"Metrica": metrics.keys(), name: metrics.values()})

def plot_portfolio_profile(df, title):
    fig, axes = plt.subplots(2, 2, figsize=(14, 8))
    fig.suptitle(f"Perfil de la cartera: {title}", fontsize=15, fontweight="bold")

    axes[0, 0].hist(df["EAD"], bins=50, color="#2F6F8F", edgecolor="white")
    axes[0, 0].set_title("Distribucion de exposiciones")
    axes[0, 0].set_xlabel("EAD")
    axes[0, 0].xaxis.set_major_formatter(FuncFormatter(lambda x, pos: f"${x/1e6:,.1f}M"))

    axes[0, 1].hist(df["PD"], bins=50, color="#7A9E3A", edgecolor="white")
    axes[0, 1].set_title("Distribucion de PD")
    axes[0, 1].set_xlabel("PD")
    axes[0, 1].xaxis.set_major_formatter(PercentFormatter(1))

    axes[1, 0].hist(df["LGD"], bins=50, color="#B35C44", edgecolor="white")
    axes[1, 0].set_title("Distribucion de LGD")
    axes[1, 0].set_xlabel("LGD")
    axes[1, 0].xaxis.set_major_formatter(PercentFormatter(1))

    size = 20 + 180 * (df["LGD"] / df["LGD"].max())
    axes[1, 1].scatter(df["PD"], df["EAD"], s=size, alpha=0.45, color="#4C5F7A", edgecolors="none")
    axes[1, 1].set_title("PD vs EAD; tamaño según LGD")
    axes[1, 1].set_xlabel("PD")
    axes[1, 1].set_ylabel("EAD")
    axes[1, 1].xaxis.set_major_formatter(PercentFormatter(1))
    axes[1, 1].yaxis.set_major_formatter(FuncFormatter(lambda x, pos: f"${x/1e6:,.1f}M"))

    plt.tight_layout()
    plt.show()

def plot_loss_distribution(losses, metrics_df, name):
    metrics = dict(zip(metrics_df["Metrica"], metrics_df[name]))
    fig, ax = plt.subplots(figsize=(12, 5.5))

    ax.hist(losses, bins=75, density=True, alpha=0.78, color="#557A95", edgecolor="white")
    ax.axvline(metrics["EL simulada"], color="#1B4332", linewidth=2.5, label="EL simulada")
    ax.axvline(metrics["VaR 95%"], color="#B08900", linestyle="--", linewidth=2, label="VaR 95%")
    ax.axvline(metrics["VaR 99%"], color="#9D4EDD", linestyle="--", linewidth=2, label="VaR 99%")
    ax.axvline(metrics["VaR 99.9%"], color="#C1121F", linestyle="--", linewidth=2, label="VaR 99.9%")

    ax.set_title(f"Distribucion simulada de perdidas - {name}", fontsize=14, fontweight="bold")
    ax.set_xlabel("Perdida")
    ax.set_ylabel("Densidad")
    ax.xaxis.set_major_formatter(FuncFormatter(lambda x, pos: f"${x/1e6:,.1f}M"))
    ax.legend(frameon=True)
    plt.tight_layout()
    plt.show()

def plot_tail(losses, name):
    sorted_losses = np.sort(losses)
    cum_prob = np.arange(1, len(sorted_losses) + 1) / len(sorted_losses)

    fig, ax = plt.subplots(figsize=(12, 5))
    ax.plot(sorted_losses, cum_prob, color="#264653", linewidth=2)
    for q, color in zip(percentiles, ["#B08900", "#9D4EDD", "#C1121F"]):
        ax.axvline(np.percentile(losses, q), color=color, linestyle="--", label=f"VaR {q}%")
    ax.set_title(f"Funcion de distribucion acumulada - {name}", fontsize=14, fontweight="bold")
    ax.set_xlabel("Perdida")
    ax.set_ylabel("Probabilidad acumulada")
    ax.xaxis.set_major_formatter(FuncFormatter(lambda x, pos: f"${x/1e6:,.1f}M"))
    ax.yaxis.set_major_formatter(PercentFormatter(1))
    ax.legend(frameon=True)
    plt.tight_layout()
    plt.show()

def interpret_portfolio(df, metrics_df, name):
    metrics = dict(zip(metrics_df["Metrica"], metrics_df[name]))
    ead_total = df["EAD"].sum()
    el_ratio = metrics["EL simulada"] / ead_total
    var99_ratio = metrics["VaR 99%"] / ead_total
    capital99_ratio = metrics["Capital economico 99%"] / ead_total

```

```

top10 = df.nlargest(10, "EAD")["EAD"].sum() / ead_total

text = f"""
La cartera tiene **{len(df):,} creditos** y una exposicion total de **{money(ead_total)}**. La perdida esperada
El **VaR al 99%** es **{money(metrics['VaR 99%'])}**, por lo que el capital economico sobre la perdida esperada
La participacion de los 10 creditos mas grandes es **{pct(top10)}**. Si esta proporcion es elevada, los percent:
"""

display(Markdown(text))

```

Cartera 1: Gubernamental

Primero se limpia la información gubernamental, convirtiendo exposición, severidad y probabilidad de incumplimiento a variables numéricas comparables. Después se revisa el perfil de la cartera antes de simular pérdidas.

```

In [18]: gub = prepare_gubernamental(raw)
perfil_gub = portfolio_profile(gub, "Gubernamental")





print(f"Numero de creditos validos: {len(gub):,}")
display(perfil_gub)
plot_portfolio_profile(gub, "Gubernamental")

```

Numero de creditos validos: 4,378

	Metrica	Gubernamental
0	Numero de creditos	4,378.0000
1	EAD total	789,852,920,716.0000
2	EAD promedio	180,414,097.9251
3	EAD mediana	13,483,797.0000
4	PD promedio simple	0.0345
5	PD ponderada por EAD	0.0338
6	LGD promedio simple	0.4001
7	LGD ponderada por EAD	0.2721
8	Perdida esperada analitica	5,262,902,144.4501
9	EL / EAD	0.0067
10	Participacion top 10 por EAD	0.1055
11	HHI de concentracion	0.0039

Perfil de la cartera: Gubernamental





```

In [19]: losses_gub = simulate_one_factor_losses(gub, rho=rho, n_sim=n_sim, seed=seed)
metricas_gub = loss_metrics(losses_gub, gub, "Gubernamental")

```

```
display(metricas_gub)
plot_loss_distribution(losses_gub, metricas_gub, "Gubernamental")
plot_tail(losses_gub, "Gubernamental")
interpret_portfolio(gub, metricas_gub, "Gubernamental")
```

	Metrica	Gubernamental
0	EL simulada	5,250,782,388.6596
1	EL analitica	5,262,902,144.4501
2	Desviacion estandar	5,316,792,805.3070
3	VaR 95%	15,554,363,137.9450
4	ES 95%	22,001,531,233.4083
5	Capital economico 95%	10,303,580,749.2854
6	VaR 99%	25,812,867,592.8875
7	ES 99%	32,839,553,421.9050
8	Capital economico 99%	20,562,085,204.2278
9	VaR 99.9%	42,211,460,116.0391
10	ES 99.9%	49,432,275,486.5082
11	Capital economico 99.9%	36,960,677,727.3795



La cartera tiene **4,378 credits** y una exposicion total de **\$789,852,920,716**. La perdida esperada simulada es **\$5,250,782,389**, equivalente a **0.66%** de la exposicion total.

El **VaR al 99%** es **\$25,812,867,593**, por lo que el capital economico sobre la perdida esperada seria aproximadamente **\$20,562,085,204** (**2.60%** de la exposicion total). El **Expected Shortfall al 99%** asciende a **\$32,839,553,422**, que resume la perdida promedio una vez que se rebasa el VaR 99%.

La participacion de los 10 credits mas grandes es **10.55%**. Si esta proporcion es elevada, los percentiles extremos pueden estar influidos por pocos acreditados grandes; si es baja, el riesgo esta mas diversificado. En esta simulacion, el supuesto de correlacion $\rho = 0.20$ hace que los incumplimientos se agrupen en escenarios macro adversos, elevando la cola derecha de la distribucion.

Cartera 2: Auto





```
In [20]: auto = prepare_auto(raw)
perfil_auto = portfolio_profile(auto, "Auto")

print(f"Numero de credits validos: {len(auto):,}")
display(perfil_auto)
plot_portfolio_profile(auto, "Auto")
```

Numero de credits validos: 4,636

	Metrica	Auto
0	Numero de credits	4,636.0000
1	EAD total	787,067,076.9000
2	EAD promedio	169,772.8811
3	EAD mediana	165,816.5750
4	PD promedio simple	0.0133
5	PD ponderada por EAD	0.0139
6	LGD promedio simple	0.7205
7	LGD ponderada por EAD	0.7204
8	Perdida esperada analitica	7,926,621.3600
9	EL / EAD	0.0101
10	Participacion top 10 por EAD	0.0098
11	HHI de concentracion	0.0003



Perfil de la cartera: Auto



```
In [21]: losses_auto = simulate_one_factor_losses(auto, rho=rho, n_sim=n_sim, seed=seed + 1)
metricas_auto = loss_metrics(losses_auto, auto, "Auto")
```

```
display(metricas_auto)
plot_loss_distribution(losses_auto, metricas_auto, "Auto")
plot_tail(losses_auto, "Auto")
interpret_portfolio(auto, metricas_auto, "Auto")
```

	Metrica	Auto
0	EL simulada	7,968,476.0601
1	EL analitica	7,926,621.3600
2	Desviacion estandar	7,146,307.2104
3	VaR 95%	21,213,195.9855
4	ES 95%	31,490,600.6766
5	Capital economico 95%	13,244,719.9255
6	VaR 99%	37,508,664.5177
7	ES 99%	49,047,474.4628
8	Capital economico 99%	29,540,188.4576
9	VaR 99.9%	64,848,272.6072
10	ES 99.9%	73,108,749.6293
11	Capital economico 99.9%	56,879,796.5471



La cartera tiene **4,636 credits** y una exposicion total de **\$787,067,077**. La perdida esperada simulada es **\$7,968,476**, equivalente a **1.01%** de la exposicion total.

El **VaR al 99%** es **\$37,508,665**, por lo que el capital economico sobre la perdida esperada seria aproximadamente **\$29,540,188 (3.75%** de la exposicion total). El **Expected Shortfall al 99%** asciende a **\$49,047,474**, que resume la perdida promedio una vez que se rebasa el VaR 99%.

La participacion de los 10 credits mas grandes es **0.98%**. Si esta proporcion es elevada, los percentiles extremos pueden estar influidos por pocos acreditados grandes; si es baja, el riesgo esta mas diversificado. En esta simulacion, el supuesto de correlacion **rho = 0.20** hace que los incumplimientos se agrupen en escenarios macro adversos, elevando la cola derecha de la distribucion.

Comparación de carteras

```
In [23]: comparacion_perfil = perfil_gub.merge(perfil_auto, on="Metrica", how="outer")
comparacion_metricas = metricas_gub.merge(metricas_auto, on="Metrica", how="outer")

print("Descripcion de las carteras")
display(comparacion_perfil)

print("Metricas de perdida")
display(comparacion_metricas)
```

Descripcion de las carteras

	Metrica	Gubernamental	Auto
0	EAD mediana	13,483,797.0000	165,816.5750
1	EAD promedio	180,414,097.9251	169,772.8811
2	EAD total	789,852,920,716.0000	787,067,076.9000
3	EL / EAD	0.0067	0.0101
4	HHI de concentracion	0.0039	0.0003
5	LGD ponderada por EAD	0.2721	0.7204
6	LGD promedio simple	0.4001	0.7205
7	Numero de credits	4,378.0000	4,636.0000
8	PD ponderada por EAD	0.0338	0.0139
9	PD promedio simple	0.0345	0.0133
10	Participacion top 10 por EAD	0.1055	0.0098
11	Perdida esperada analitica	5,262,902,144.4501	7,926,621.3600

Metricas de perdida

	Metrica	Gubernamental	Auto
0	Capital economico 95%	10,303,580,749.2854	13,244,719.9255
1	Capital economico 99%	20,562,085,204.2278	29,540,188.4576
2	Capital economico 99.9%	36,960,677,727.3795	56,879,796.5471
3	Desviacion estandar	5,316,792,805.3070	7,146,307.2104
4	EL analitica	5,262,902,144.4501	7,926,621.3600
5	EL simulada	5,250,782,388.6596	7,968,476.0601
6	ES 95%	22,001,531,233.4083	31,490,600.6766
7	ES 99%	32,839,553,421.9050	49,047,474.4628
8	ES 99.9%	49,432,275,486.5082	73,108,749.6293
9	VaR 95%	15,554,363,137.9450	21,213,195.9855
10	VaR 99%	25,812,867,592.8875	37,508,664.5177
11	VaR 99.9%	42,211,460,116.0391	64,848,272.6072